

Modul_4_VINIX

April 10, 2026

1 Laporan Modul 4: Exploratory Data Analysis (EDA) Tokopedia Product Reviews 2025

Notebook ini dibuat untuk memenuhi penugasan Modul 4: Exploratory Data Analysis (EDA). Analisis dilakukan menggunakan Python dengan bantuan pustaka Pandas, Matplotlib, dan Seaborn untuk mengeksplorasi tren harga produk, volume penjualan, distribusi kategori, serta sentimen pelanggan berdasarkan dataset ulasan produk Tokopedia.

Kelompok 17 Anggota: 1. Abdulhadi Muntashir 2. Naufal Pancar Nugraha 3. M Hafid Ramadhan

```
[ ]: from google.colab import files
      uploaded = files.upload()
```

<IPython.core.display.HTML object>

Saving Dataset Tugas Data Science M4.rar to Dataset Tugas Data Science M4 (2).rar

```
[ ]: !apt-get install unrar-free -y
      !unrar-free x "Dataset Tugas Data Science M4.rar"
      !ls
```

Reading package lists... Done

Building dependency tree... Done

Reading state information... Done

unrar-free is already the newest version (1:0.0.2-0.1).

0 upgraded, 0 newly installed, 0 to remove and 7 not upgraded.

unrar 0.0.2 Copyright (C) 2004 Ben Asselstine, Jeroen Dekkers

Extracting from /content/Dataset Tugas Data Science M4.rar

unknown archive type, only plain RAR 2.0 supported(normal and solid archives), SFX and Volumes are NOT supported!

All OK

'Dataset Tugas Data Science M4 (1).rar' sample_data

'Dataset Tugas Data Science M4 (2).rar' tokopedia_product_reviews_2025.csv

'Dataset Tugas Data Science M4.rar'

```
[ ]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_style("whitegrid")
plt.rcParams["figure.figsize"] = (10, 6)
```

```
[ ]: df = pd.read_csv("tokopedia_product_reviews_2025.csv")

# Ubah review_date ke datetime
df["review_date"] = pd.to_datetime(df["review_date"], errors="coerce")

# Tampilkan 5 data awal
display(df.head())

# Info dataset
print("Shape dataset:", df.shape)
print("\nInformasi dataset:")
print(df.info())

print("\nMissing values:")
print(df.isna().sum())
```

	review_text	review_date	review_id \
0	baru sekali ini terima brg dr belanja online d...	2024-12-22	1134256160
1	cocok bgt aku sama telur nya. nga Amis menurut...	2025-02-25	1242584634
2	Telornya sudah sampai di rumah dengan kemasan ...	2025-07-15	1573444677
3	Telor sudah diterima dengan baik dan tidak ada...	2025-07-20	1581728541
4	Alhamdulillah penjual amanah,Telor nya terbaik...	2023-04-24	881041355

	product_name	product_category \
0	Telur Ayam Kampung Asli - Telur Mengandung Ome...	Makanan & Minuman
1	Telur Ayam Kampung Asli - Telur Mengandung Ome...	Makanan & Minuman
2	Telur Ayam Kampung Asli - Telur Mengandung Ome...	Makanan & Minuman
3	Telur Ayam Kampung Asli - Telur Mengandung Ome...	Makanan & Minuman
4	Telur Ayam Kampung Asli - Telur Mengandung Ome...	Makanan & Minuman

	product_variant	product_price \
0	Box Polos	87000
1	Box Polos	87000
2	Box Polos	87000
3	Box Polos	87000
4	Box Full Design	87000

	product_url	product_id	rating \
0	https://www.tokopedia.com/indofarmproduct/telu...	4601033481	5
1	https://www.tokopedia.com/indofarmproduct/telu...	4601033481	5

2	https://www.tokopedia.com/indofarmproduct/telu...	4601033481	5
3	https://www.tokopedia.com/indofarmproduct/telu...	4601033481	5
4	https://www.tokopedia.com/indofarmproduct/telu...	4601033481	5

	sold_count	shop_id	sentiment_label
0	1000000	8672687	positive
1	1000000	8672687	positive
2	1000000	8672687	positive
3	1000000	8672687	positive
4	1000000	8672687	positive

Shape dataset: (65543, 13)

Informasi dataset:

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 65543 entries, 0 to 65542

Data columns (total 13 columns):

#	Column	Non-Null Count	Dtype
0	review_text	65543 non-null	object
1	review_date	65543 non-null	datetime64[ns]
2	review_id	65543 non-null	int64
3	product_name	65543 non-null	object
4	product_category	65543 non-null	object
5	product_variant	26749 non-null	object
6	product_price	65543 non-null	int64
7	product_url	65543 non-null	object
8	product_id	65543 non-null	int64
9	rating	65543 non-null	int64
10	sold_count	65543 non-null	int64
11	shop_id	65543 non-null	int64
12	sentiment_label	65543 non-null	object

dtypes: datetime64[ns](1), int64(6), object(6)

memory usage: 6.5+ MB

None

Missing values:

review_text	0
review_date	0
review_id	0
product_name	0
product_category	0
product_variant	38794
product_price	0
product_url	0
product_id	0
rating	0
sold_count	0

```
shop_id          0
sentiment_label  0
dtype: int64
```

```
[ ]: print(df_clean["sentiment_label"].value_counts())
      print(df_clean["product_category"].value_counts())
```

```
sentiment_label
positive    23360
neutral      348
negative     298
Name: count, dtype: int64
product_category
Makanan & Minuman    17859
Kesehatan             6147
Name: count, dtype: int64
```

1.1 Tahap 1: Data Preparation & Overview

Pada tahap awal, dilakukan proses pembacaan dataset, pemeriksaan struktur data, pengecekan tipe data, serta identifikasi missing values. Tahap ini penting untuk memastikan bahwa data sudah siap digunakan dalam proses analisis berikutnya, terutama pada kolom tanggal, harga produk, jumlah penjualan, dan label sentimen.

```
[ ]: # Cek tipe data
      print(df.dtypes)

      # Cek missing values
      missing_values = df.isna().sum().sort_values(ascending=False)
      print("\nMissing values per kolom:")
      print(missing_values)

      # Cleaning sederhana
      df_clean = df.copy()

      # Pastikan kolom numerik benar
      df_clean["product_price"] = pd.to_numeric(df_clean["product_price"],
      ↪errors="coerce")
      df_clean["sold_count"] = pd.to_numeric(df_clean["sold_count"], errors="coerce")

      # Drop baris yang kosong pada kolom penting
      df_clean = df_clean.dropna(subset=["review_date", "product_price",
      ↪"sold_count", "sentiment_label", "product_category"])

      print("\nShape setelah cleaning:", df_clean.shape)
```

```
review_text      object
review_date      datetime64[ns]
review_id        int64
```

```

product_name      object
product_category  object
product_variant   object
product_price     int64
product_url       object
product_id        int64
rating            int64
sold_count        int64
shop_id           int64
sentiment_label   object
dtype: object

```

Missing values per kolom:

```

product_variant    38794
review_date        0
review_id          0
product_name       0
review_text        0
product_category   0
product_price      0
product_url        0
product_id         0
rating             0
sold_count         0
shop_id            0
sentiment_label    0
dtype: int64

```

Shape setelah cleaning: (65543, 13)

1.1.1 Interpretasi 1

Berdasarkan hasil pengecekan missing values, kolom yang memiliki nilai kosong paling banyak adalah `product_variant` (38.794 data kosong). Namun, kolom-kolom utama seperti `review_date`, `product_price`, `sold_count`, dan `sentiment_label` tidak memiliki missing values. Secara khusus, kolom `review_text` memiliki 0 data kosong, sehingga tidak diperlukan strategi imputasi atau penghapusan baris untuk teks ulasan.

Strategi yang digunakan adalah membiarkan kolom `product_variant` tetap apa adanya karena bukan variabel inti analisis. Selain itu, kolom `review_date` dikonversi ke format `datetime` untuk analisis temporal. Baris dengan nilai kosong pada kolom numerik penting telah dibersihkan menggunakan `dropna` agar tidak mendistorsi hasil perhitungan.

1.2 Tahap 2: Analisis Univariat (Distribusi & Frekuensi)


Tahap ini bertujuan untuk memahami karakteristik dasar dari data. Analisis dilakukan terhadap frekuensi ulasan per kategori produk serta distribusi harga produk di dalam dataset. Visualisasi univariat membantu mengidentifikasi pola dominan, ketimpangan antar kategori, dan sebaran harga pasar secara umum.

```
[ ]: category_order = df_clean["product_category"].value_counts().index

plt.figure(figsize=(10, 6))
sns.countplot(data=df_clean, y="product_category", order=category_order)

plt.title("Frekuensi Jumlah Ulasan per Kategori Produk")
plt.xlabel("Jumlah Ulasan")
plt.ylabel("Kategori Produk")
plt.tight_layout()
plt.show()

# Tampilkan frekuensi kategorinya juga
display(df_clean["product_category"].value_counts().reset_index().
        ↪rename(columns={"index": "product_category", "product_category":
        ↪"total_reviews"}))
```



	total_reviews	count
0	Makanan & Minuman	17859
1	Olahraga	15600
2	Pertukangan	11500
3	Kesehatan	8959
4	Handphone & Tablet	7423
5	Elektronik	4202

1.2.1 Interpretasi 2

Berdasarkan grafik frekuensi kategori produk, kategori **Makanan & Minuman** merupakan kategori dengan jumlah ulasan terbanyak, disusul oleh **Olahraga** dan **Pertukangan**. Hal ini menunjukkan bahwa aktivitas pelanggan paling tinggi terkonsentrasi pada beberapa kategori tertentu, sehingga distribusi ulasan antar kategori tidak sepenuhnya merata.

Ketimpangan jumlah ulasan ini mengindikasikan bahwa beberapa kategori memiliki eksposur pasar dan interaksi pelanggan yang jauh lebih besar dibanding kategori lain. Oleh karena itu, analisis lanjutan terhadap kategori dengan ulasan terbanyak dapat memberikan insight bisnis yang lebih berdampak.


```
[ ]: # Membuat dua subplots untuk perbandingan
fig, ax = plt.subplots(1, 2, figsize=(16, 6))

# Plot 1: Distribusi original dengan skala Log (untuk melihat outlier)
sns.histplot(df_clean["product_price"], bins=50, kde=True, ax=ax[0])
ax[0].set_title("Distribusi Harga Produk (Skala Log)")
ax[0].set_xscale("log")
ax[0].set_xlabel("Harga Produk (IDR)")

# Plot 2: Distribusi Produk <= Rp1.000.000 (untuk melihat pasar dominan)
df_filtered = df_clean[df_clean["product_price"] <= 1000000]
sns.histplot(df_filtered["product_price"], bins=30, kde=True, ax=ax[1],
             color='orange')
ax[1].set_title("Distribusi Produk di Bawah Rp1 Juta")
ax[1].set_xlabel("Harga Produk (IDR)")

plt.tight_layout()
plt.show()

# Menampilkan statistik deskriptif
print(df_clean["product_price"].describe())
```



```

count      6.554300e+04
mean       5.421295e+05
std        2.365557e+06
min        1.000000e+02
25%        2.990000e+04
50%        8.000000e+04
75%        2.146870e+05
max        9.999900e+07
Name: product_price, dtype: float64

```

1.2.2 Interpretasi 3

Distribusi harga produk menunjukkan pola yang sangat **right-skewed**, di mana ekor distribusi memanjang jauh ke arah kanan akibat keberadaan produk premium. Meskipun harga maksimum mencapai Rp99.999.000, mayoritas produk terkonsentrasi pada rentang harga rendah hingga menengah.

Hal ini diperkuat oleh nilai **Median (50%) sebesar Rp80.000**, yang menunjukkan bahwa separuh dari seluruh produk dalam dataset dihargai di bawah angka tersebut. Rentang harga yang paling mendominasi pasar berada pada kelompok produk terjangkau (di bawah Rp214.687 berdasarkan kuartil ketiga). Dengan demikian, strategi agregator sebaiknya tetap berfokus pada volume penjualan produk mass-market, karena produk premium hanya menyumbang fraksi kecil dari total observasi.

1.3 Tahap 3: Deteksi Outlier (Anomali Data)

Pada tahap ini dilakukan analisis distribusi harga produk berdasarkan kategori sentimen pelanggan. Tujuannya adalah untuk melihat apakah terdapat kecenderungan hubungan antara harga produk dengan sentimen yang diberikan, sekaligus mendeteksi keberadaan outlier harga ekstrem pada masing-masing kelompok sentimen.

```


[ ]: plt.figure(figsize=(10, 6))
      sns.boxplot(
          data=df_clean,
          x="sentiment_label",
          y="product_price",
          order=["positive", "neutral", "negative"]
      )

      plt.title("Distribusi Harga Produk Berdasarkan Sentimen")
      plt.xlabel("Sentiment Label")
      plt.ylabel("Product Price")
      plt.yscale("log")
      plt.tight_layout()
      plt.show()

      display(
          df_clean.groupby("sentiment_label")["product_price"]
          .describe()[["count", "mean", "50%", "min", "max"]]
      )

```


)



	count	mean	50%	min	max
sentiment_label					
negative	798.0	185482.943609	68000.0	500.0	10499000.0
neutral	802.0	169813.961347	59000.0	1000.0	10499000.0
positive	63943.0	551250.170245	80500.0	100.0	99999000.0

1.3.1 Interpretasi 4

Boxplot menunjukkan bahwa distribusi harga pada masing-masing kategori sentimen memiliki pola yang cukup bervariasi, namun secara umum produk dengan sentimen **positive** tersebar pada rentang harga yang lebih luas dibanding kelompok **neutral** dan **negative**. Hal ini menunjukkan bahwa produk dengan harga tinggi tidak selalu identik dengan sentimen negatif, karena banyak produk mahal juga tetap memperoleh ulasan positif.

Selain itu, terlihat adanya beberapa **outlier harga ekstrem** di setiap kelompok sentimen, terutama pada sentimen positif. Kehadiran outlier ini menandakan bahwa terdapat produk dengan harga jauh di atas mayoritas data, sehingga seller perlu mengevaluasi apakah produk premium tersebut benar-benar memberikan value yang sesuai dengan ekspektasi pelanggan.

1.4 Tahap 4: Analisis Multivariat (Tren & Korelasi)

Tahap ini berfokus pada dua hal utama, yaitu tren jumlah ulasan dari waktu ke waktu dan hubungan antara harga produk dengan total penjualan. Analisis multivariat membantu memahami pola temporal, dinamika pasar, serta keterkaitan antara harga, performa penjualan, dan sentimen pelanggan.


```
[ ]: # Membuat kolom year, month, dan year_month
df_clean["year"] = df_clean["review_date"].dt.year
df_clean["month"] = df_clean["review_date"].dt.month
df_clean["year_month"] = df_clean["review_date"].dt.to_period("M").astype(str)

# Agregasi jumlah ulasan per bulan
monthly_reviews = df_clean.groupby("year_month").size().
    ↪reset_index(name="total_reviews")

plt.figure(figsize=(14, 6))
sns.lineplot(data=monthly_reviews, x="year_month", y="total_reviews",
    ↪marker="o")

plt.title("Tren Jumlah Ulasan per Bulan")
plt.xlabel("Periode (Tahun-Bulan)")
plt.ylabel("Jumlah Ulasan")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()

display(monthly_reviews.sort_values("total_reviews", ascending=False).head(10))
```



	year_month	total_reviews
117	2025-10	1802
105	2024-10	1711
118	2025-11	1698
116	2025-09	1664
104	2024-09	1659
115	2025-08	1604
103	2024-08	1570
106	2024-11	1540

107	2024-12	1497
79	2022-08	1444

1.4.1 Interpretasi 5


Grafik tren jumlah ulasan per bulan menunjukkan bahwa partisipasi ulasan pelanggan mengalami fluktuasi dari waktu ke waktu, dengan beberapa periode tertentu menampilkan lonjakan yang cukup jelas. Lonjakan ini mengindikasikan adanya momentum transaksi yang lebih tinggi dibanding periode lainnya.

Secara bisnis, kenaikan jumlah ulasan pada bulan-bulan tertentu sangat mungkin berkaitan dengan kampanye promosi marketplace, periode diskon besar, atau meningkatnya aktivitas belanja musiman. Oleh karena itu, seller dapat memanfaatkan periode ramai tersebut untuk mengoptimalkan stok, promosi, dan kualitas layanan agar volume penjualan meningkat tanpa menurunkan kepuasan pelanggan.

```
[ ]: plt.figure(figsize=(10, 6))
sns.scatterplot(
    data=df_clean,
    x="product_price",
    y="sold_count",
    hue="sentiment_label",
    alpha=0.7
)

plt.title("Hubungan Harga Produk dan Total Penjualan Berdasarkan Sentimen")
plt.xlabel("Product Price")
plt.ylabel("Sold Count")
plt.xscale("log")
plt.yscale("log")
plt.legend(title="Sentiment")
plt.tight_layout()
plt.show()

# Korelasi Spearman
corr_spearman = df_clean["product_price"].corr(df_clean["sold_count"],
↪method="spearman")
print("Korelasi Spearman antara product_price dan sold_count:", corr_spearman)
```



Korelasi Spearman antara `product_price` dan `sold_count`: -0.4094472192415116

1.4.2 Interpretasi 6

Scatter plot menunjukkan bahwa hubungan antara harga produk dan total penjualan cenderung **berlawanan arah**, di mana produk dengan harga lebih rendah umumnya memiliki volume penjualan yang lebih tinggi. Hal ini menunjukkan bahwa produk yang terjangkau cenderung lebih mudah menjangkau pasar yang lebih luas.

Dari warna titik berdasarkan sentimen, terlihat bahwa produk dengan penjualan tinggi tidak selalu identik hanya dengan sentimen positif, meskipun sentimen positif tetap mendominasi dataset. Artinya, tingginya volume penjualan belum tentu sepenuhnya mencerminkan kepuasan pelanggan, sehingga seller tetap perlu menjaga kualitas produk dan pengalaman pembelian.

1.5 Tahap 5: Kesimpulan & Rekomendasi Bisnis

Berdasarkan keseluruhan analisis yang telah dilakukan, terdapat beberapa insight utama yang dapat dijadikan dasar dalam pengambilan keputusan bisnis.

1.5.1 Kesimpulan Akhir

Berdasarkan hasil exploratory data analysis, dapat disimpulkan bahwa aktivitas ulasan pelanggan paling banyak terkonsentrasi pada kategori tertentu, terutama **Makanan & Minuman**, yang menunjukkan bahwa kategori ini memiliki tingkat interaksi pasar yang paling tinggi. Selain itu, distribusi harga produk dalam dataset cenderung didominasi oleh produk murah hingga menengah, sementara produk mahal hanya muncul sebagai sebagian kecil data dan sering terlihat sebagai outlier.

Dari sisi performa bisnis, tren jumlah ulasan memperlihatkan adanya periode-periode tertentu yang mengalami peningkatan aktivitas pelanggan. Hal ini menunjukkan bahwa momentum promosi atau musim belanja memiliki pengaruh terhadap jumlah interaksi dan transaksi. Sementara itu, hubungan antara harga dan jumlah penjualan menunjukkan kecenderungan bahwa produk dengan harga lebih rendah lebih mampu menghasilkan volume penjualan yang tinggi.

Sebagai rekomendasi, seller di Tokopedia sebaiknya lebih fokus mengoptimalkan strategi harga pada produk entry-level hingga middle-range karena segmen ini tampak paling dominan di pasar. Selain itu, seller juga perlu melakukan evaluasi pada produk yang memiliki sentimen netral dan negatif, terutama untuk memastikan bahwa harga yang ditawarkan sudah sebanding dengan kualitas produk dan ekspektasi pelanggan.

Seller juga disarankan untuk memaksimalkan performa toko pada periode dengan lonjakan ulasan, misalnya dengan menyiapkan stok yang cukup, meningkatkan respons layanan pelanggan, dan menjalankan promosi yang lebih agresif. Dengan demikian, peluang peningkatan penjualan dapat dimanfaatkan secara optimal tanpa mengorbankan kepuasan pelanggan.