

PROJECT-BASED INTERNSHIP VINIX7

Modul 6: Supervised Learning - Feature Engineering & Penanganan Data Imbalance

Konteks Bisnis: Klien *brand aggregator* Tokopedia kita menuntut model *Machine Learning* yang sesungguhnya untuk mengotomatisasi deteksi komplain pelanggan. Jika di modul sebelumnya Anda hanya mengevaluasi model statis, kini Anda bertugas membangun model klasifikasi dari nol menggunakan data mentah.

Tantangan utama Anda adalah mengolah berbagai tipe data (teks, numerik, kategorikal) dan mengatasi tantangan distribusi target pada data *e-commerce*. Klien ingin model yang sangat sensitif terhadap komplain (sentimen negatif) agar tim *Customer Service* (CS) dapat merespons keluhan dengan sigap sebelum pelanggan pindah ke kompetitor (*churn*).

Instruksi Umum:

- Pengerjaan dilakukan menggunakan Jupyter Notebook atau Google Colab.
- Setiap selesai menjalankan tahap utama, Anda **wajib** menambahkan sel *Markdown* untuk menuliskan interpretasi teknis dan dampaknya terhadap bisnis.

Tahap 1: Data Cleansing & Handling 'Neutral'

1. Load dataset `tokopedia_product_reviews_2025.csv` menggunakan Pandas.
2. Hapus baris data yang memiliki label sentimen `'neutral'`.
3. Buang (*drop*) kolom yang berpotensi menyebabkan *data leakage* atau tidak relevan: `review_date`, `review_id`, `product_name`, `product_url`, `product_id`, `shop_id`, dan `rating`.

Tahap 2: Feature Engineering & Preprocessing

1. Ekstrak fitur baru bernama `review_length` yang berisi jumlah karakter teks dari kolom `review_text`.
2. Ubah target target `'positive'` menjadi 1 dan `'negative'` menjadi 0. Pisahkan *features* (X) dan *target* (y).
3. Lakukan `train_test_split` (80% Train, 20% Test) dengan `random_state=42`.
Penting: Lakukan ini *sebelum* tahap transformasi untuk mencegah *Data Leakage*.
4. Gunakan `ColumnTransformer` untuk melakukan *Fit & Transform* pada data Train, lalu hanya *Transform* pada data Test dengan skema:
 - `review_text`: Gunakan `TfidfVectorizer` (batasi `max_features=1000`).
 - `product_category` & `product_variant`: Gunakan *One-Hot Encoding*.
 - `product_price`, `sold_count`, `review_length`: Gunakan `StandardScaler`.

Tahap 3: Eksperimen Model (Baseline)

1. Latih model **XGBoost Classifier** atau **Random Forest Classifier** atau **model klasifikasi lainnya** menggunakan data Train yang sudah diproses. Biarkan seluruh parameter secara *default*.
2. Lakukan prediksi pada data Test dan tampilkan `classification_report`.
3. **Interpretasi 1:** Analisis hasil metrik Anda. Bagaimana nilai metrik evaluasi (terutama *Recall*) untuk kelas 0 (negatif)? Secara teknis, mengapa model menghasilkan pola metrik seperti itu? Apa bahayanya bagi operasional CS jika model *baseline* ini di-deploy?

Tahap 4: Eksperimen Penanganan Imbalance & Tuning Tugas Anda sekarang adalah memodifikasi model agar mampu mengenali komplain (kelas 0) secara optimal. Anda dibebaskan menggunakan pendekatan penanganan *imbalance* data.

1. Pilih minimal **satu pendekatan** berikut dan ujikan bersama `GridSearchCV` (cv=3 atau 5):
 - Menggunakan parameter pembobotan bawaan algoritma (misal: `scale_pos_weight` pada XGBoost atau `class_weight='balanced'` pada Tree/SVC).
 - Menggunakan teknik *Undersampling* (misal: `RandomUnderSampler` dari library `imblearn`).
 - Menggunakan teknik *Oversampling* (misal: `SMOTE` dari library `imblearn`).
(Catatan: Jika Anda menggunakan teknik resampling, Anda **wajib** menggunakan `Pipeline` dari library `imblearn` (bukan dari `sklearn`) agar tidak terjadi *Data Leakage* saat proses *Cross-Validation internal*).
 - Optimalisasi dan pendekatan lainnya.
2. Latih model hasil eksperimen Anda, lalu uji pada data Test. Tampilkan `classification_report` terbarunya.
3. **Interpretasi 2 (Analisis Kondisi Model):**
 - Pendekatan penyeimbangan apa yang Anda gunakan?
 - Evaluasi perubahan performa model. Jika terjadi perubahan signifikan atau *trade-off* (tarik-ulur) yang ekstrem antara nilai *Recall* dan *Precision* pada kelas 0 setelah Anda menangani *imbalance*, jelaskan mengapa secara teknis algoritma memberikan keluaran/tebakan seperti itu.

Tahap 5: Kesimpulan Akhir & Keputusan Bisnis

Interpretasi 3: Apapun hasil performa metrik akhir model Anda di Tahap 4 (meskipun belum sempurna atau tidak seimbang), bertindaklah sebagai Data Scientist yang harus memberikan rekomendasi final kepada manajemen. Apakah model eksperimen Anda di Tahap 4 lebih layak digunakan sebagai **Sistem Triase (Prioritas) Tiket CS** dibandingkan model Baseline? Gunakan argumen komparasi estimasi beban kerja CS (menimbang risiko penanganan *False Positive* vs *False Negative*) untuk membenarkan argumen teknis Anda.

KRITERIA PENILAIAN

1. Data Preparation & Preprocessing (20%)

- **Maksimal:** Peserta secara tepat membersihkan data dari variabel *noise* dan *leakage*, meletakkan proses *data splitting* di urutan yang tepat sebelum manipulasi skala, dan berhasil merangkai transformasi berbagai tipe data (*text*, *num*, *cat*) menggunakan skema pemrograman yang efisien (seperti `ColumnTransformer`).

2. Implementasi Eksperimen & Validasi (30%)

- **Maksimal:** Peserta mengimplementasikan teknik penanganan ketidakseimbangan kelas secara terprogram. Peserta menerapkan *Cross-Validation* (CV) dengan kaidah yang benar. Jika menggunakan metode *resampling* (*Under/Oversampling*), peserta berhasil menggunakan arsitektur *Pipeline* khusus untuk mencegah terjadinya kebocoran data (*data leakage*) ke dalam *validation fold* selama proses CV.

3. Ketajaman Interpretasi Teknis (Tahap 3 & Tahap 4) (30%)

- **Maksimal:** Peserta mampu mengidentifikasi masalah utama pada model *baseline*. Pada Tahap 4, peserta tidak sekadar membaca angka metrik, melainkan mampu menguraikan fenomena analitik yang terjadi (khususnya relasi/ *trade-off* metrik kelas minoritas) yang merupakan efek samping logis dari paksaan algoritma dalam mengenali pola data yang telah direayasa distribusinya.

4. Kualitas Keputusan Bisnis (Tahap 5) (20%)

- **Maksimal:** Peserta mampu menerjemahkan keluaran matematis algoritma ke dalam narasi bahasa operasional dan finansial. Argumen kelayakan *deployment* didukung oleh perbandingan simulasi beban kerja (seperti waktu/sumber daya yang terbuang) dan prioritas pencegahan kehilangan pelanggan (*churn*) secara logis dan realistis.